Kubernetes 中 HPA 与 VPA 的差异及生产落地建议

概述

Kubernetes 提供了多种自动扩缩容机制，其中最常用的两种是水平 Pod 自动扩缩容 (HPA) 和垂直 Pod 自动扩缩容 (VPA)。这两种机制分别从不同的角度解决了资源管理的问题，但它们在实际应用中也存在一些冲突和挑战。本文将详细探讨 HPA 与 VPA 的差异，并提供生产环境中的实施建议。

HPA 与 VPA 的定义与工作原理

HPA (Horizontal Pod Autoscaler)

目标：HPA 通过动态调整 Pod 的副本数量来应对流量变化，适用于处理突发的流量高峰 [2]。 - **触发条件**：HPA 会定期检查指标（如 CPU 使用率、内存使用率等），并与预设的目标值进行比较。当指标超过阈值时，HPA 会增加 Pod 副本数；反之则减少 [3]。 - **调整对象**：HPA 调整的是 Pod 的副本数量，而不是单个 Pod 的资源配置 [4]。

VPA (Vertical Pod Autoscaler)

目标：VPA 通过调整单个 Pod 的资源请求（CPU 和内存）来优化资源利用率，适用于需要稳定资源配置的应用 [2]。 - **触发条件**：VPA 会监控 Pod 的资源使用情况，并根据历史数据推荐新的资源配置。如果当前配置与推荐值不一致，VPA 会更新 Pod 的资源配置 [5]。 - **调整对象**：VPA 调整的是单个 Pod 的资源请求和限制，而不是 Pod 的副本数量 [6]。

HPA 与 VPA 的主要差异

目标与调整对象

- **HPA**：调整 Pod 的副本数量，适用于处理突发流量 [7]。
- **VPA**：调整单个 Pod 的资源请求和限制，适用于优化资源利用率 [8]。

触发条件

- **HPA**：基于 CPU、内存等资源使用率或自定义指标 [3]。
- **VPA**：基于 Pod 的实际资源使用情况 [5]。

冲突与协调

- **冲突**：同时使用 HPA 和 VPA 时，可能会产生冲突。例如，HPA 根据 CPU 使用率增加 Pod 数量，而 VPA 可能会增加单个 Pod 的 CPU 请求，导致 HPA 的计算结果不稳定 [9]。
- **协调**：为了安全地使用 HPA 和 VPA，可以将它们配置为针对不同的指标。例如，HPA 可以基于 CPU 使用率，而 VPA 可以基于内存使用率 [10]。

生产环境中的实施建议

配置 HPA

- **关键参数**：
- **目标 CPU 利用率**：设置合理的 CPU 利用率阈值，通常为 60% 到 80% [11]。
- **最小和最大副本数**：根据业务需求设置合适的副本数范围 [11]。
- **扩缩容冷却时间**：设置适当的冷却时间，避免频繁扩缩容 [11]。

配置 VPA

- **模式选择**：
- **Off 模式**：仅提供建议，不自动更新 Pod 配置 。
- **Initial 模式**：仅对新创建的 Pod 应用推荐配置 。
- **Auto 模式**：自动更新 Pod 配置，但可能导致 Pod 重启 。
- **资源限制**：确保 VPA 推荐的资源配置不超过节点的实际资源上限 。

协同使用 HPA 和 VPA

- **分离指标**：HPA 和 VPA 应该针对不同的资源指

[truncated]

参考文献

[1] akvanewsletter.substack.com — Kubernetes Autoscaling: HPA Vs VPA URL: https://akvanewsletter.substack.com/p/kubernetes-autoscaling-hpa-vs-vpa 原文片段：「Kubernetes Autoscaling: HPA Vs VPA Abhishek Veeramalla (AKVA) Subscribe Sign in Kubernetes Autoscaling: HPA Vs VPA Pods in Motion When to Multiply, When to Amplify Abhishek Veeramalla (AKVA) Jul 16, 2025 89 8 4 Share Hello Welcome again to the AKVAverse, I'm Abhishek Veeramalla,...」

[2] hwchiu.com — Kubernetes 中 VPA, HPA, CA, CPA 的差異是什麼? | hwchiu learning note URL: https://www.hwchiu.com/docs/2023/autoscaler 原文片段：「Kubernetes 中 VPA, HPA, CA, CPA 的差異是什麼? | hwchiu learning note Skip to main content On this page Kubernetes 內有各式各樣的自動擴展機制，譬如 HPA(Horizontal Pod Autoscaling)，該技術可根據不同條件而動態調整 Pod 的副本數量，使得 Pod 有更好的能力去處理當前的流量而不需要管理人員不停介入調整數量。 除了 HPA 外，Kubernetes 還有其他相關的機制，如 VPA, CA 以及 CPA，本篇文章就針對這些類別進...」

[3] scaleops.com — HPA vs VPA: Choosing the Right Kubernetes Autoscaling Strategy in 2025 URL: https://scaleops.com/blog/hpa-vs-vpa 原文片段：「HPA vs VPA: Choosing the Right Kubernetes Autoscaling Strategy in 2025 Skip to content Book a Demo Get Started Sign In All articles HPA vs VPA: Kubernetes Autoscaling Compared (2026 Guide) Konstantin Zelmanovich May 27, 2026 Featured Table of contents Stop paying for resources yo...」

[4] blog.csdn.net — 终极指南：Kubernetes VPA与HPA协同实战，破解弹性伸缩困境-CSDN博客 URL: https://blog.csdn.net/gitblog_00525/article/details/152112761 原文片段：「终极指南：Kubernetes VPA与HPA协同实战，破解弹性伸缩困境-CSDN博客 终极指南：Kubernetes VPA与HPA协同实战，破解弹性伸缩困境 原创 于 2026-01-09 03:17:54 发布 · 880 阅读 · CC 4.0 BY-SA版权 版权声明：本文为博主原创文章，遵循 CC 4.0 BY-SA 版权协议，转载请附上原文出处链接和本声明。 · 收录于 当前文章被以下社区和专栏收录： 终极指南：Kubernetes VPA与HPA协同实战，破解弹性伸缩困境 【免费下载链接】autoscaler Kubernetes的自动扩...」

[5] oneuptime.com — How to Handle VPA and HPA Together for CPU and Memory Autoscaling URL: https://oneuptime.com/blog/post/2026-02-09-vpa-hpa-together-cpu-memory-autoscaling/view 原文片段：「How to Handle VPA

and HPA Together for CPU and Memory Autoscaling Skip to main content How to Handle VPA and HPA Together for CPU and Memory Autoscaling Learn how to safely use Vertical Pod Autoscaler and Horizontal Pod Autoscaler together by splitting metrics, using VPA in recom…」

[6] sedai.io — Kubernetes Autoscaling Explained: HPA, VPA & Best Practices (2026) | Sedai URL: https://sedai.io/blog/kubernetes-autoscaling 原文片段：「Kubernetes Autoscaling Explained: HPA, VPA & Best Practices (2026) | Sedai Introducing Sed: Your cloud & AI assistant Meet Sed Kubernetes Autoscaling: How It Works and Best Practices Benjamin Thomas CTO May 29, 2026 Featured Key takeaways Use Kubernetes autoscaling to adjust reso…」

[7] icertglobal.com — How to choose between HPA and VPA for Kubernetes scaling? | iCertGlobal Community URL: https://www.icertglobal.com/community/kubernetes-hpa-vs-vpa-scaling-strategies 原文片段：「How to choose between HPA and VPA for Kubernetes scaling? | iCertGlobal Community Cloud Technology How to choose between HPA and VPA for Kubernetes scaling? BR Asked by Brandon Miller · 14-05-2025 ▲ 0 upvotes 15,571 views 0 comments The question I am managing a cluster where some…」

[8] help.aliyun.com — 安装和配置VPA实现Pod资源垂直伸缩-容器服务 Kubernetes 版 ACK-阿里云 URL: https://help.aliyun.com/zh/ack/ack-managed-and-ack-dedicated/user-guide/vertical-pod-autoscaling 原文片段：「安装和配置VPA实现Pod资源垂直伸缩-容器服务 Kubernetes 版 ACK-阿里云 官方文档 如果您希望根据 Pod 实际的资源使用情况，动态调整和优化资源配置，以确保 Pod 能够调度到资源充足的节点上，建议您为业务容器开启垂直伸缩 VPA（Vertical Pod Autoscaler）功能。VPA 能够监控 Pod 的资源消耗模式，灵活推荐 CPU 和内存资源分配的配置，并在适当的情况下自动进行调整，而不调整 Pod 的副本数量。这种能力更适用于需要稳定资源配置的有状态应用的扩容等场景。 阅读前提示 为了帮助您更好地使用 VPA 功能，建议…」

[9] docs.cloud.google.com — GKE 中 AI/机器学习工作负载的简化自动扩缩概念 | GKE AI/ML | Google Cloud Documentation URL: https://docs.cloud.google.com/kubernetes-engine/docs/concepts/machine-learning/understand-autoscaling?hl=zh-cn 原文片段：「GKE 中 AI/机器学习工作负载的简化自动扩缩概念 | GKE AI/ML | Google Cloud Documentation 跳至主要内容 / 控制台 English Deutsch Español Español – América Latina Français Indonesia Italiano

Português Português – Brasil עברית 中文 – 简体 中文 – 繁體 日本語 한국어 登录 Google Kubernetes Engine (GKE) GKE AI/ML 免费开始使用吧 Google 会使用…」

[10] lixueduan.com — Kubernetes教程(十二)---VPA:垂直 Pod 自动扩缩容 - 探索云原生 URL: https://www.lixueduan.com/posts/kubernetes/12-vpa 原文片段：「Kubernetes教程(十二)---VPA:垂直 Pod 自动扩缩容 - 探索云原生 Kubernetes教程(十二)---VPA:垂直 Pod 自动扩缩容 意琦行 收录于 Kubernetes 2022-10-14 00:00:00 约 2900 字 预计阅读 6 分钟 - 次阅读 目录 本文主要记录 k8s 中与 HPA 相对应的 VPA 功能，包括架构、大致实现以及 demo。 什么是 VPA？ VPA 全称 Vertical Pod Autoscaler,即垂直 Pod 自动扩缩容 ,它根据容器资源使用率自动设置 CPU 和内存的 request…」

[11] cnblogs.com — 云原生：使用HPA和VPA实现集群扩缩容 - Hello-Brand - 博客园 URL: https://www.cnblogs.com/wzh2010/p/18031123 原文片段：「云原生：使用HPA和VPA实现集群扩缩容 - Hello-Brand - 博客园 Brand 一生践行韦特莱法则，一生保持高执行力高效率… 云原生：使用HPA和VPA实现集群扩缩容 1 背景 我们之前介绍过，随着业务流量上涨之后，我们的系统需要适时的进行扩容。 数据存储层我们也介绍过MySQL的扩容 Scale UP（纵向扩展） 和 Scale Out（横向扩展） 垂直拆分（Scale Up 纵向扩展）：包括垂直分库、垂直分表 水平拆分（Scale Out 横向扩展）：包括库内分表、分库分表 详细可以参考笔者这几篇：《 MySQL全面瓦解28：分库…」