Kubernetes 中 HPA 与 VPA 的差异及生产落地建议

概述

Kubernetes 提供了多种自动扩缩容机制，其中最常用的是 Horizontal Pod Autoscaler (HPA) 和 Vertical Pod Autoscaler (VPA)。这两种机制分别从水平和垂直两个维度对应用进行扩缩容，以应对不同的需求和场景。本文将详细探讨 HPA 与 VPA 的差异，并提供生产环境中的实施建议。

HPA 与 VPA 的基本概念

HPA (Horizontal Pod Autoscaler)

HPA 是 Kubernetes 的核心功能之一，它根据观察到的指标（如 CPU、内存或自定义指标）自动调整 Deployment、ReplicaSet 或 StatefulSet 的 Pod 副本数量 [1]。HPA 的主要目标是通过增加或减少 Pod 的数量来应对流量变化，从而保持系统的稳定性和性能。

VPA (Vertical Pod Autoscaler)

VPA 是一个附加组件，它根据 Pod 的实际资源使用情况自动调整单个 Pod 的资源请求和限制 [6]。VPA 的主要目标是优化每个 Pod 的资源分配，避免资源浪费和性能瓶颈。

HPA 与 VPA 的差异

目标

- **HPA**：通过增加或减少 Pod 的数量来应对流量变化，适用于需要快速响应流量波动的应用。
- **VPA**：通过调整单个 Pod 的资源请求和限制来优化资源利用率，适用于需要长期稳定运行的应用。

触发条件

- **HPA**：基于 CPU、内存或其他自定义指标的变化。当这些指标超过预设阈值时，HPA 会自动增加或减少 Pod 的数量 [4]。
- **VPA**：基于 Pod 的实际资源使用情况。VPA 会持续监控 Pod 的资源使用情况，并根据历史数据生成资源建议 [6]。

调整对象

- **HPA**：调整 Pod 的副本数量，不改变单个 Pod 的资源配置。
- **VPA**：调整单个 Pod 的资源请求和限制，不改变 Pod 的副本数量。

操作模式

- **HPA**：非破坏性操作，不会重启 Pod。
- **VPA**：有多种更新模式，包括 `Off`、`Initial`、`Recreate` 和 `InPlaceOrRecreate`。在 `Recreate` 模式下，VPA 会重启 Pod 以应用新的资源配置 [6]。

生产环境中的实施建议

选择合适的扩缩容策略

- **HPA** 适用于需要快速响应流量波动的应用，例如 Web 应用或 API 服务。HPA 可以迅速增加或减少 Pod 的数量，以应对突发的流量高峰 [5]。
- **VPA** 适用于需要长期稳定运行的应用，例如后台处理任务或数据处理服务。VPA 可以优化每个 Pod 的资源分配，避免资源浪费和性能瓶颈 [5]。

避免资源冲突

- 不要同时使用 HPA 和 VPA 对同一组 Pod 进行扩缩容，因为它们可能会相互干扰，导致资源浪费和系统不稳定 [7]。
- 如果必须同时使用 HPA 和 VPA，可以考虑让 HPA 基于自定义指标（如请求计数）进行扩缩容，而 VPA 管理资源限制 [7]。

配置最佳实践

- **HPA**：
- 设置合理的 CPU 利用率目标。
- 定义最小和最大副本数。
- 设置适当的扩缩容冷却时间 [8]。
- **VPA**：
- 使用

[truncated]

参考文献

[1] scaleops.com — HPA vs VPA: Choosing the Right Kubernetes Autoscaling Strategy in 2025 URL: https://scaleops.com/blog/hpa-vs-vpa 原文片段：「HPA vs VPA: Choosing the Right Kubernetes Autoscaling Strategy in 2025 Skip to content Book a Demo Get Started Sign In All articles HPA vs VPA: Kubernetes Autoscaling Compared (2026 Guide) Konstantin Zelmanovich May 27, 2026 Featured Table of contents Stop paying for resources yo...」

[2] blog.csdn.net — 终极指南：Kubernetes VPA与HPA协同实战，破解弹性伸缩困境-CSDN博客 URL: https://blog.csdn.net/gitblog_00525/article/details/152112761 原文片段：「终极指南：Kubernetes VPA与HPA协同实战，破解弹性伸缩困境-CSDN博客 终极指南：Kubernetes VPA与HPA协同实战，破解弹性伸缩困境 原创 于 2026-01-09 03:17:54 发布 · 881 阅读 · CC 4.0 BY-SA版权 版权声明：本文为博主原创文章，遵循 CC 4.0 BY-SA 版权协议，转载请附上原文出处链接和本声明。 · 收录于 当前文章被以下社区和专栏收录： 终极指南：Kubernetes VPA与HPA协同实战，破解弹性伸缩困境 【免费下载链接】autoscaler Kubernetes的自动扩...」

[3] akvanewsletter.substack.com — Kubernetes Autoscaling: HPA Vs VPA URL: https://akvanewsletter.substack.com/p/kubernetes-autoscaling-hpa-vs-vpa 原文片段：「Kubernetes Autoscaling: HPA Vs VPA Abhishek Veeramalla (AKVA) Subscribe Sign in Kubernetes Autoscaling: HPA Vs VPA Pods in Motion When to Multiply, When to Amplify Abhishek Veeramalla (AKVA) Jul 16, 2025 89 8 4 Share Hello Welcome again to the AKVAverse, I’m Abhishek Veeramalla,...」

[4] hwchiu.com — Kubernetes 中 VPA, HPA, CA, CPA 的差異是什麼? | hwchiu learning note URL: https://www.hwchiu.com/docs/2023/autoscaler 原文片段：

「Kubernetes 中 VPA, HPA, CA, CPA 的差異是什麼? | hwchiu learning note Skip to main content On this page Kubernetes 內有各式各樣的自動擴展機制，譬如 HPA(Horizontal Pod Autoscaling)，該技術可根據不同條件而動態調整 Pod 的副本數量，使得 Pod 有更好的能力去處理當前的流量而不需要管理人員不停介入調整數量。 除了 HPA 外，Kubernetes 還有其他相關的機制，如 VPA, CA 以及 CPA，本篇文章就針對這些類別進...」

[5] rack2cloud.com — VPA vs HPA in Kubernetes: Differences, Use Cases, and When to Use Each URL: https://www.rack2cloud.com/vpa-vs-hpa-kubernetes 原文片段：「VPA vs HPA in Kubernetes: Differences, Use Cases, and When to Use Each Skip to content The VPA vs HPA decision is one of the most misunderstood choices in Kubernetes resource management. Most Kubernetes teams reach for HPA first. It’s visible, it’s familiar, and the CPU metric da...」

[6] scaleops.com — Kubernetes VPA: Architecture, Limitations & Best Practices (2026) URL: https://scaleops.com/blog/kubernetes-vpa 原文片段：「Kubernetes VPA: Architecture, Limitations & Best Practices (2026) Skip to content Book a Demo Get Started Sign In All articles Kubernetes VPA: Architecture, Limitations, and Production Best Practices Rob Croteau Nov 4, 2024 Featured Table of contents Stop paying for resources you...」

[7] icertglobal.com — How to choose between HPA and VPA for Kubernetes scaling? | iCertGlobal Community URL: https://www.icertglobal.com/community/kubernetes-hpa-vs-vpa-scaling-strategies 原文片段：「How to choose between HPA and VPA for Kubernetes scaling? | iCertGlobal Community Cloud Technology How to choose between HPA and VPA for Kubernetes scaling? BR Asked by Brandon Miller · 14-05-2025 ▲ 0 upvotes 15,572 views 0 comments The question I am managing a cluster where some...」

[8] dev.to — Kubernetes Autoscaling Internals: HPA and VPA Under the Hood - DEV Community URL: https://dev.to/piyushjajoo/kubernetes-autoscaling-internals-hpa-and-vpa-under-the-hood-4e0g 原文片段：「Kubernetes Autoscaling Internals: HPA and VPA Under the Hood - DEV Community Add reaction Like Unicorn Exploding Head Raised Hands Fire Jump to Comments Save Boost Copy link Copied to Clipboard Share to X Share to LinkedIn Share to Facebook Share to Mastodon Report Abuse This pos...」

[9] openkruise.io — 基于HPA的极致弹性调度最佳实践 | OpenKruise URL: https://openkruise.io/zh/docs/best-practices/elastic-deployment 原文片段：「基于HPA的极致弹性调度最佳实践 | OpenKruise Skip to main content If you like OpenKruise, give it a star on GitHub ！ 版本：v1.9 本页总览 自 0.10.0 版本开始，OpenKruise 提出了一种基于旁路（by-pass）架构的多域管理组件 --- WorkloadSpread。它允许用户将 Workload 的副本在不同节点、不同机房、甚至不同云厂商中进行多域化编排，并允许用户对不同域的副本进行差异化配置。WorkloadSpread 可以以无侵入…」