向量数据库主要选型维度与常见产品概述

核心选型维度

向量数据库选型并非追求“最强”，而是需在多维工程约束下达成最优平衡。关键维度包括：**数据规模与吞吐需求**（如Chroma适用于≤100万向量，Milvus支持1亿至10亿级）、**部署运维能力**（自托管vs全托管）、**混合检索能力**（结构化过滤+向量相似度联合查询）、**更新实时性**（Qdrant更新性能优于Milvus）、**多模态支持深度**（Weaviate插件架构最完善）、**现有技术栈耦合度**（PGVector对PostgreSQL用户零迁移成本），以及**可观测性与索引调优成熟度**（Milvus与Qdrant表现最佳）[2]。

主流产品对比与适用场景

下表综合工程特性与典型规模，提炼六大主流方案：

方案	最佳使用场景	优势	局限	典型规模
Chroma	本地开发、桌面级RAG	零依赖、迭代快、易上手	不支持超大规模/分布式	≤100万向量
Milvus	企业级集群、十亿向量、多租户	GPU索引、高吞吐、分片+多副本HA	运维复杂度高	1亿～10亿向量
Weaviate	结构化+向量混合搜索、知识库	GraphQL接口、Filter能力强、多模态插件丰富	部署复杂度略高	1百万～5亿向量
PGVector	已大量使用PostgreSQL的团队	无需新系统、SQL原生、维护成本最低	索引能力弱于专业向量库	≤数百万向量
Qdrant	高性能落地、云原生、实时更新	Rust实现、高并发、毫秒级响应	生态广度略逊于Milvus	百万～数亿向量
Pinecone			成本高、闭源	

方案	最佳使用场景	优势	局限	典型规模
	拒绝自运维、快速上线商用场景	全托管服务、自动索引优化、SLA保障		视订阅套餐而定

一句话选型口诀：轻量用Chroma，本地用PGVector，大规模用Milvus，语义+结构搜索用Weaviate，全托管选Pinecone，高性能选Qdrant[2]。

架构差异决定能力边界

Milvus采用分布式微服务架构，支撑企业级高并发与十亿级索引；Weaviate基于模块化插件设计，天然适配多模态与混合检索；PGVector则以扩展形式嵌入PostgreSQL，实现关系型与向量能力的无缝融合[2]。不同架构直接映射其工程能力上限——例如，Milvus的GPU加速索引与Weaviate的GraphQL过滤能力，均源于底层设计哲学差异。选型必须匹配业务阶段：Agentic AI记忆系统需低延迟与高并发[1]，而企业知识库则更依赖语义检索精度与结构化元数据协同[2

[truncated

[truncated]

参考文献

[1] aws.amazon.com — 相得益彰 — 亚马逊云科技向量存储选型推荐 | 亚马逊AWS官方博客 URL: https://aws.amazon.com/cn/blogs/china/complementary-advantages-aws-vector-storage-selection-recommendations 原文片段：「相得益彰 — 亚马逊云科技向量存储选型推荐 | 亚马逊AWS官方博客 Skip to Main Content 亚马逊AWS官方博客 相得益彰 — 亚马逊云科技向量存储选型推荐 随着AI系统，特别是Agentic AI系统的快速发展，对向量数据存储的需求日益增长。典型应用场景包括： 实时推荐与个性化服务。基于用户行为向量和内容特征向量，实现商品推荐、内容分发、广告投放等个性化服务，要求毫秒级的响应时间和高并发处理能力。 知识库的构建和语义检索。企业知识管理系统需要从海量文档中快速定位语义相关内容，为大语言模型提供精准的上下文信息，提升回答质量和领域专业性…」

[2] jimmysong.io — 向量数据库选型实践 | Jimmy Song URL: https://jimmysong.io/zh/book/ai-handbook/rag/vector-databases 原文片段：「向量数据库选型实践 | Jimmy Song 跳转到主要内容 跳转到导航 跳转到页脚 站内搜索 搜索 类型: 所有

类型 当前图书 博客 图书 公告 播客 键盘导航: Tab 下一个结果 | Shift+Tab 上一个结果 | ↑↓ 导航 | Enter 打开链接 | Esc 关闭 向量数据库选型实践 已完成 内容导航 图书内部搜索… 向量数据库是 RAG 系统的“语义底座”，选型决定检索质量与系统可扩展性。工程师必须理解架构与能力，才能做出最优决策。 向量数据库在 RAG（Retrieval-Augmented Generation, 检索增强生成）…」

[3] cloudian.com — Vector Database: How It Works, Use Cases & Top 6 in 2026 URL: https://cloudian.com/guides/ai-infrastructure/vector-database-how-it-works-use-cases-top-6-in-2026 原文片段：「Vector Database: How It Works, Use Cases & Top 6 in 2026 Blog Partners Events Press Support Search Language 日本語 Deutsch English Pricing Products › ← Back Cloudian Products HyperStore Object Storage HyperScale AIDP HyperStore File Services HyperIQ Observability & Analytics HyperCa…」