向量数据库选型维度与主流产品概览

核心选型维度

向量数据库选型需兼顾技术能力与工程现实，核心维度包括：**性能（毫秒级响应、高并发）、可扩展性（支持百万至十亿级向量）、一致性与可用性（多副本、分片、HA）、过滤能力（metadata filter强度）、多模态支持（跨文本/图像/音频检索）、部署复杂度（是否需自运维）、生态集成（SQL兼容、GraphQL、插件体系）及成本模型（开源免费 vs. 托管服务订阅）**[2]。在RAG系统中，其作为“语义底座”，直接决定上下文召回质量、延迟与系统扩展上限[2]。

关键能力对比

方案	最佳场景	典型规模	优势	局限
Chroma	本地开发、桌面级RAG	≤100万向量	零依赖、易用、迭代快	不支持超大规模/分布式
Milvus	企业级集群、十亿向量、多租户	1亿～10亿向量	GPU索引、高吞吐、多副本HA	运维成本高
Weaviate	结构化+向量混合搜索、知识库	100万～5亿向量	GraphQL接口、Filter能力强、插件丰富	部署略复杂
PGVector	已深度使用PostgreSQL的团队	≤数百万向量	无需新系统、关系型融合、成本低	索引能力弱于专业库
Qdrant	高性能落地、云原生	百万～数亿向量	Rust实现、实时更新快、高并发	生态略逊Milvus
Pinecone	快速上线、免运维	视套餐而定	全托管、开箱即用	成本高、闭源

数据来源：[2]

主流产品特性解析

Milvus采用分布式架构，支持分片与多副本，适用于企业级海量语料与高并发场景；Weaviate基于模块化插件设计，对多模态检索与结构化过滤支持最完善；PGVector深度集成PostgreSQL，适合已有SQL资产团队低成本迁移；Qdrant以Rust构建，实时更新性能优于Milvus；Chroma轻量简洁，专为原型与本地RAG优化；Pinecone则提供全托管服务，牺牲可控性换取交付速度[2]。工程实践中，索引策略亦需匹配：Milvus推荐IVF+PQ，Qdrant/Weaviate首选HNSW，PGVector亦优先HNSW[2]。最终选型非“越强越好”，而应权衡预算、团队能力、数据规模与更新频率等现实约束[2]。

参考文献

[1] aws.amazon.com — 相得益彰 — 亚马逊云科技向量存储选型推荐 | 亚马逊AWS官方博客 URL: https://aws.amazon.com/cn/blogs/china/complementary-advantages-aws-vector-storage-selection-recommendations 原文片段：「相得益彰 — 亚马逊云科技向量存储选型推荐 | 亚马逊AWS官方博客 Skip to Main Content 亚马逊AWS官方博客 相得益彰 — 亚马逊云科技向量存储选型推荐 随着AI系统，特别是Agentic AI系统的快速发展，对向量数据存储的需求日益增长。典型应用场景包括： 实时推荐与个性化服务。基于用户行为向量和内容特征向量，实现商品推荐、内容分发、广告投放等个性化服务，要求毫秒级的响应时间和高并发处理能力。 知识库的构建和语义检索。企业知识管理系统需要从海量文档中快速定位语义相关内容，为大语言模型提供精准的上下文信息，提升回答质量和领域专业性…」

[2] jimmysong.io — 向量数据库选型实践 | Jimmy Song URL: https://jimmysong.io/zh/book/ai-handbook/rag/vector-databases 原文片段：「向量数据库选型实践 | Jimmy Song 跳转到主要内容 跳转到导航 跳转到页脚 站内搜索 搜索 类型: 所有类型 当前图书 博客 图书 公告 播客 键盘导航: Tab 下一个结果 | Shift+Tab 上一个结果 | ↑↓ 导航 | Enter 打开链接 | Esc 关闭 向量数据库选型实践 已完成 内容导航 图书内部搜索… 向量数据库是 RAG 系统的“语义底座”，选型决定检索质量与系统可扩展性。工程师必须理解架构与能力，才能做出最优决策。 向量数据库在 RAG（Retrieval-Augmented Generation, 检索增强生成）…」

[3] dev3lop.com — Vector Database Selection Criteria for Embedding-Based Applications | Dev3lop URL: https://dev3lop.com/blog/vector-database-selection-criteria-for-embedding-based-applications 原文片段：「Vector Database Selection Criteria for Embedding-Based Applications | Dev3lop Skip

to main content Blog Vector Database Selection Criteria for Embedding-Based Applications Today's transformative organizations are harnessing the unprecedented power of embedding-based applications...」

[4] unimon.co.th — What is a Vector Database? A Complete Guide to How It Works, Top Product Comparisons, and RAG Applications | Unimon URL: https://unimon.co.th/en/blog/vector-database-guide 原文片段：「What is a Vector Database? A Complete Guide to How It Works, Top Product Comparisons, and RAG Applications | Unimon What is a Vector Database? A Complete Guide to How It Works, Top Product Comparisons, and RAG Applications LLM Operations & RAG Updated : April 1, 2026 Published :...」